

# **Sprawozdanie z przedmiotu Programowanie Równoległe i Rozproszone**

**Google Colab**

Wykonał:

Imię i nazwisko

Magdalena Paszko

Nr indeksu

76024

Grupa

L2

Prowadzący : dr inż. Krzysztof Szerszeń

# Zadanie 1

Korzystając z kodu:


[https://colab.research.google.com/github/tensorflow/graphics/blob/master/tensorflow\\_graphics/g3doc/\\_index.ipynb#scrollTo=39Vm7iSONAHs](https://colab.research.google.com/github/tensorflow/graphics/blob/master/tensorflow_graphics/g3doc/_index.ipynb#scrollTo=39Vm7iSONAHs)

Wystarczy podmieniając link i zmienić nazwę i możemy dostać inny model 3d np.:



- Kostka ( <http://www.eg-models.de/rsrc/sample.obj> ):



- Dynia:



- Czajnik ( <http://groups.csail.mit.edu/graphics/classes/6.837/F03/models/teapot.obj> ):



## Znajdź i opisz inne ciekawe zastosowanie biblioteki Tensorflow

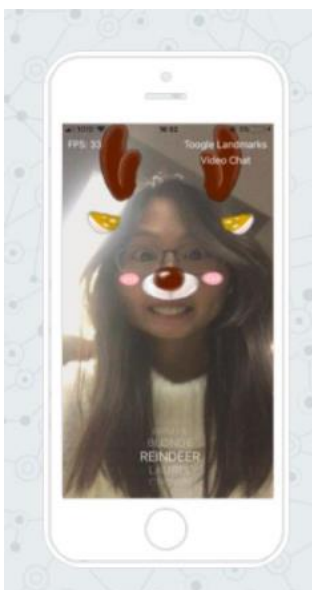
### 1. Co zawiera TensorFlow?

Otwarty w 2015 r. TensorFlow to platforma Google do tworzenia modeli głębokiego uczenia się. Deep Learning to jedna z kilku kategorii modeli uczenia maszynowego (ML), które wykorzystują wielowarstwowe sieci neuronowe. Biblioteka TensorFlow umożliwia użytkownikom wykonywanie funkcji poprzez tworzenie wykresów obliczeniowych.


TensorFlow szturmem podbił świat, ponieważ jest darmowy, (stosunkowo) łatwy w użyciu i zapewnia programistom z podstawowymi środowiskami uczenia maszynowego dostęp do potężnej biblioteki zamiast tworzenia wszystkich modeli sztucznej inteligencji od podstaw. TensorFlow i towarzyszące mu moduły ułatwiają tworzenie oprogramowania ML / AI zarówno dla aplikacji mobilnych, jak i usług zaplecza.

## 2. Zastosowanie:

- Konwolucyjne sieci neuronowe (CNN) do rozpoznawania i przetwarzania obrazu



Jedną z wielu aplikacji CNN jest pomoc maszynom w rozpoznawaniu obrazów i nadaniu im znaczenia w sposób intuicyjny dla ludzi. Na przykład oznacza to, że komputer rozpoznaje kolorowe kropki na obrazie, łącząc się w ciasto. Aby sprawdzić dokładność, sztuczną inteligencję można szkolić na danych szkoleniowych, w przypadku których poprawne odpowiedzi są już dostępne. CNN nauczy się rozpoznawać obraz, sprawdzi, czy jest poprawny i poprawi swoją zdolność rozumienia kolorowych klastrów. Ale prawdziwa wydajność daje sztucznej inteligencji nowy zestaw danych, aby zobaczyć, jak działa.



**Uczenie się transferu** to technika skrótów, która wykorzystuje w pełni wyszkolony model sztucznej inteligencji i dostosowuje go do nowej klasyfikacji obrazu, zamiast ponownego **uczenia** modelu AI od zera za każdym razem. ImageNet jest dobrym źródłem do dostarczania zestawu danych do uczenia obrazu.

CNN można zastosować w wielu dziedzinach, takich jak:

- **klasyfikacja obrazów** dla aplikacji biznesowych, takich jak nasz przypadek dopasowywania i sortowania zapasów

- **diagnostyka medyczna** w celu dopasowania danych obrazu pacjenta do znanych wizualnych objawów chorób
- **czujniki liniowe do zastosowań sportowych** do oceny wejścia-wyjścia na podstawie danych obrazu o wysokiej rozdzielczości
- **ocena ryzyka** dla wniosków (np. o ubezpieczenie lub kartę kredytową)

Korzyści z wczesnego rozpoczęcia pracy z AI / ML polegają na tym, że pierwsi użytkownicy będą mieli większe zbiory danych do pracy niż konkurenci po latach.

➤ Modele sekwencyjne (Seq2Seq) dla funkcji związanych z językiem ludzkim

Modele Sekwencja do Sekwencji (Seq2Seq) wykorzystują rekurencyjne sieci neuronowe jako element składowy, dostarczając wiele par zdań podczas uczenia modelu, abyśmy mogli wygenerować jedno zdanie z innego zdania. Te pary zdań mogą być dowolne. Na przykład, jeśli są to słowa z dwóch różnych języków, model można wykorzystać do tłumaczenia. Kiedy jest to para wiadomości konwersacyjnych, model może być używany do botów czatu.

Ciekawostką jest to, że musimy po prostu wprowadzić nieprzetworzoną sekwencję słów i możemy odzyskać wynikową sekwencję słów z przeważnie poprawną gramatyką (nie jest to doskonała, ale przynajmniej zrozumiała). Oznacza to, że modele seq2seq mogą uczyć się modelu języka z próbki szkoleniowej i pośrednio uczyć się go podczas szkolenia, co zwykle nie ma miejsca w tradycyjnym NLP, gdzie model języka musi być jawnie nauczany.

Modelowanie języka (w skrócie prawdopodobieństwo pojawienia się słowa przy poprzedniej sekwencji słów) jest kluczem do wielu interesujących problemów, takich jak:

- Rozpoznawanie mowy do tworzenia napisów w czasie rzeczywistym
- Chatboty AI, takie jak nasz kantoński Chatbot for Telegram
- Wirtualni asystenci, tacy jak Apple Siri, Amazon's Alexa i Google Assistant
- Tłumaczenie maszynowe
- Podsumuj dokumenty
- Wsadowe podpisy graficzne

➤ Wielkoskalowe modele liniowe do analizy danych i prostych prognoz behawioralnych

Modele liniowe na dużą skalę są prostsze niż złożone sieci neuronowe z wieloma warstwami. Ale zgodnie z zasadą używania odpowiedniego narzędzia do właściwego zadania, modele liniowe są nadal potężne, gdy są stosowane w odpowiednich przypadkach. W porównaniu z głębokimi sieciami neuronowymi modele liniowe uczą się szybciej, mogą dobrze działać w przypadku dużych zestawów funkcji oraz być łatwiej interpretowane i debugowane. Ogólnie rzecz biorąc, modele liniowe są skuteczne w przetwarzaniu danych i tworzeniu prostych prognoz, aby pomóc firmom z dużymi zbiorami danych.

Modele liniowe mogą być używane do klasyfikacji binarnej (przewidywanie wyniku a lub b), klasyfikacji wieloklasowej (przewidywanie jednego z wielu wyników) i regresji (przewidywanie wartości liczbowej). Modele te mogą być używane do oceny dużych zbiorów danych, takich jak dane spisowe lub dane finansowe.

Na przykład Amazon ML wykorzystuje modele liniowe w e-commerce, aby pomóc sprzedawcom w przedstawianiu sugestii, takich jak:

- Czy klient kupi ten produkt, czy nie kupi tego produktu? (Klasyfikacja binarna)
- Czy ten produkt to komputer, smartfon czy akcesorium? (Klasyfikacja wieloklasowa)
- Jaka jest odpowiednia cena dla tego modelu samochodu i rocznika? (Regresja)